

به نام خدا

تمرین کامپیوتری دوم بهینه سازی محدب
دکتر یاسایی

مبین خطیب

۹۹۱۰۶۱۱۴



۱ برآورد درست نمایی بیشینه

۱.۱:

log-likelihood برای مشاهده N_t رخداد برابر است با :

$$-\lambda_t - N_t \log \lambda_t + \log N_t!$$

از آنجایی که این رخداد ها به دلیل توزیع پواسون مستقل هستند میتوانیم همه این ۲۴ رخداد را با هم در نظر بگیریم که بتوانیم به محاسبه log-likelihood نزدیک تر شویم بنابراین negative log-likelihood برای مجموعه مشاهدات رویداد ها برابر است با :

$$\Sigma_{t=1}^{24} = \lambda_t - N_t \log \lambda_t + \log(N_t!) \quad (۱)$$

بنابراین تخمین بیشینه درست نمایی برای λ_t مینیمم خواهد کرد negative log-likelihood روی مشاهدات N_1, \dots, N_{24} که این مینیمایز کردن با حل مسئله بهینه سازی زیر برای $\lambda_1, \dots, \lambda_{24}$ انجام خواهد شد:

$$\begin{aligned} \text{minimize } \Sigma_{t=1}^{24} &= \lambda_t - N_t \log \lambda_t + \log(N_t!) \\ \text{subject to } &\lambda \geq 0 \end{aligned} \quad (۲)$$

اما در پاسخ بالا $N_t = 0$ کاور نمیشود چون فقط $\lambda_t > 0$ در نظر گرفته ایم برای این حالت میتوانیم مینیمایزشن را روی هر λ_t انجام دهیم اول فرض میکنیم $N_t > 0$ باشد آنگاه مینیمایزر $1 - N_t/\lambda_t = 0$ را ارضا خواهد کرد بنابراین $\lambda_t = N_t$ برای $N_t = 0$ خواهد بود در واقع ما λ_t را به قید $\lambda_t \geq 0$ مینیمایز کردیم که در نتیجه این خواهیم داشت $\lambda_t = 0$ بنابراین در همه حالت ها تخمین ML ما خواهد بود $N_t = \lambda_t$ در واقع اگر مشاهدات ما N_t رخداد باشد احتمالا میانگین این اتفاق ها رخ داده است.

۱.۲:

برای این کار باید مسئله بهینه سازی زیر را حل کنیم:

$$\begin{aligned} \text{minimize } &\left(\sum_{t=1}^{24} (\lambda_t - N_t \log \lambda_t) + \sum_{t=1}^{23} (\lambda_{t+1} - \lambda_t)^2 + (\lambda_1 - \lambda_{24})^2 \right) \\ \text{subject to } &\lambda \geq 0 \end{aligned} \quad (۳)$$

به طوری که $\lambda \in R^{24}$ ترم ثابت را در نظر نگرفتیم چون وابسته به λ_t نیست


۱.۳: هرچه $\rho \rightarrow \infty$ میل دهیم λ_t ها به برابری نزدیک تر میشوند بنابراین وقتی داشته باشیم $\lambda = \tilde{\lambda}$ بنابراین خواهیم داشت:

$$\begin{aligned} \text{minimize } &24\tilde{\lambda} - \left(\sum_{t=1}^{24} N_t \log(\tilde{\lambda}) \right) \\ \text{subject to } &\tilde{\lambda} \geq 0 \end{aligned} \quad (۴)$$

در واقع راه حل ما مدل پواسون در حالت ثابت است که در آن $\lambda_t = \tilde{\lambda} = \bar{N} = \Sigma_i N_i / 24$ که این میانگین رخداد های هر ساعت از روز که در کل روز رخ داده میباشد.

۱.۴،۵:

$\rho = 100$, log likelihood = -43.76226937992665



۲ سطوح فعالیت بهینه

۲.۱:

مسئله بهینه سازی را میتوانیم به صورت زیر عنوان کنیم:

$$\text{maximize} \quad \left(\sum_{j=1}^n r_j(x_j) \right) \quad \text{subject to} \quad x \geq 0 \quad Ax \leq c^{max} \quad (5)$$

اگر به مسئله بالا دقت کنیم میبینیم که تابع هدف مسئله ما مقعر است و در اینجا مجموعه نامساوی خطی همان تابع constraint ماست و برای تبدیل به فرم LP تعریف میکنیم تابع زیر را به شکل:

$$\min \quad (p_j x_j, p_j q_j + p_j^{disc}(x_j - q_j)) \quad (6)$$

که در نتیجه r_j مقعر است و همچنین میتوانیم بگوییم که $r_j(x_j) \geq u_j$ است اگر و تنها اگر:

$$p_j(x_j) \geq u_j, p_j^{disc}(x_j - q_j) \geq u_j \quad (7)$$

آنگاه با توجه به شرایط بالا میتوانیم فرم LP را تشکیل دهیم:

$$\begin{aligned} &\text{maximize} \quad (1^T u) \\ &\text{subject to} \quad x \geq 0 \\ &\quad \quad \quad Ax \leq c^{max} \\ &\quad \quad \quad p_j(x_j) \geq u_j, \\ &\quad \quad \quad p_j^{disc}(x_j - q_j) \geq u_j \end{aligned}$$

حال فقط میماند درست کردن x ، آخرین مجموعه محدودیت‌ها در LP تضمین می‌کند که $u_i \leq r_i(x)$ ، که میتوانیم تساوی زیر را جایگزین عبارت پیشین کنیم

$$u_i = r_i(x)$$

را بگیریم، در این صورت دو هدف یکسان هستند.

۲.۲:

```

x.value =
[[ 3.99999996]
 [22.49999989]
 [30.99999995]
 [ 1.50000005]]
r =
[[ 11.99999989]
 [ 32.49999989]
 [138.99999981]
 [ 9.00000032]]
tot_r =
[192.49999991]
avgPrice =
[[3.          ]
 [1.44444445]
 [4.48387097]
 [6.          ]]

```

:۳.۱

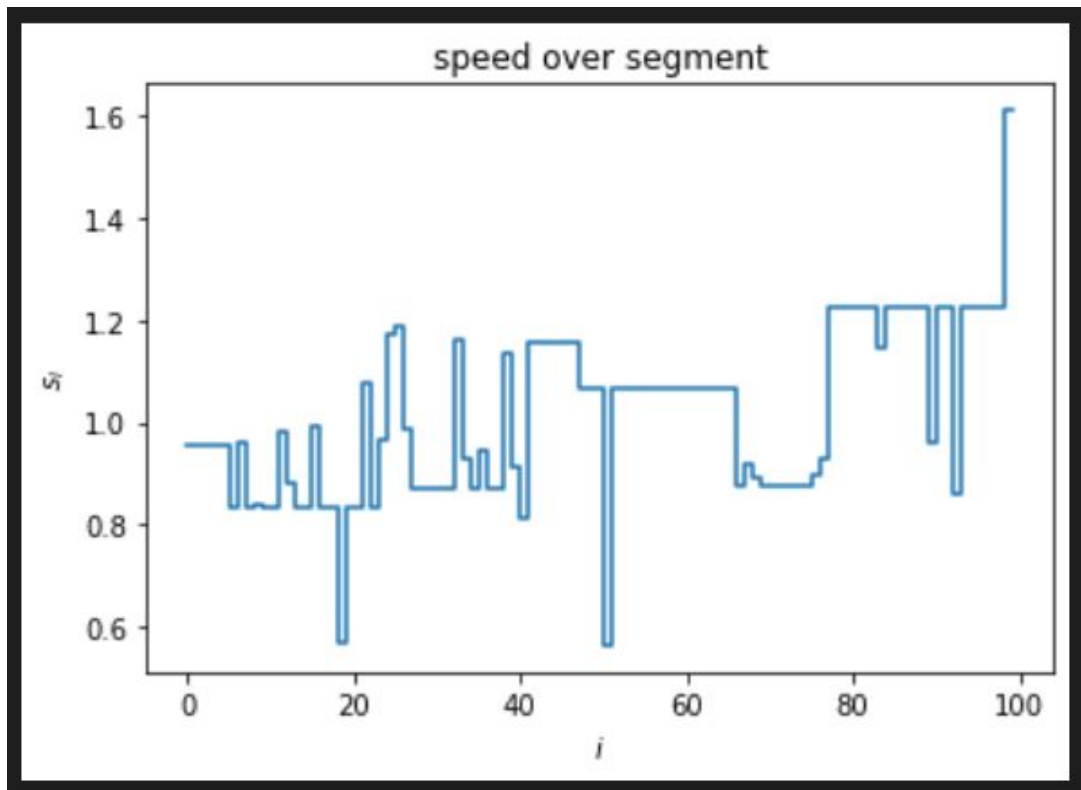
سوختی که برای بخش i ام مصرف شده برابر است با $d_i/s_i\Phi(s_i)$ بنابراین مجموع سوخت استفاده شده برابر است با $\sum_{i=1}^n d_i/s_i\Phi(s_i)$ وسیله نقلیه در زمان $\tau_i = \sum_{j=1}^i d_j/s_j$ به نقطه i میرسد بنابراین مسئله بهینه سازی ما به شکل:

$$\begin{aligned}
 & \text{minimize} \quad (\sum_{i=1}^n d_i/s_i\Phi(s_i)) \\
 & \text{subject to} \quad s_i^{min} \leq s_i \leq s_i^{max} (i = 1, \dots, n) \\
 & \quad \tau_i^{min} \leq \sum_{j=1}^i d_j/s_j \leq \tau_i^{max} (i = 1, \dots, n)
 \end{aligned}$$

این مسئله یک مسئله محدب نیست تابع هدف ما باید در s_i محدب باشد و همچنین نا برابری ها محدب نیستند با تغییر متغیر میتوانیم این ضعف ها را بپوشانیم. اگر تعریف کنیم $x_i = d_i/s_i$ آنگاه مسئله بهینه سازی ما به شکل:

$$\begin{aligned}
 & \text{minimize} \quad (\sum_{i=1}^n x_i\Phi(d_i/x_i)) \\
 & \text{subject to} \quad d_i/s_i^{max} \leq x_i \leq d_i/s_i^{min} (i = 1, \dots, n) \\
 & \quad \tau_i^{min} \leq \sum_{j=1}^i x_j \leq \tau_i^{max} (i = 1, \dots, n)
 \end{aligned}$$

این مسئله محدب است تابع $x_i\Phi(d_i/x_i)$ پرسپکتیوی از Φ محدب است بنابراین تابع هدف ما محدب است چون جمع وزن های توابع محدب است و همچنین constraint های ما در x خطی هستند و اگر مسئله را برای x_i^* حل کنیم سرعت بهینه را با استفاده از $s_i^* = d_i/x_i^*$ بدست خواهیم آورد. ۳.۲:



:۴.۱

$1/x$ محدب نیست مگر اینکه دامنه را به R^{++} محدود کرد در واقع می‌توانیم بنویسیم $invpos(x) + invpos(y)$ که تابع $invpos$ دامنه اش R^{++} بنابراین قید های $x \geq 0, y \geq 0$ را شامل خواهد شد.

:۴.۲

xy مقعر نیست ولی می‌توانیم قیدمان را به شکل $x \geq invpos(y)$ بنویسیم همچنین اگر در اینجا جای x ، y را عوض کنیم باز هم همه چیز اوکی خواهد بود.

:۴.۳

اینجا هم مسئله وقتی مشکل دار خواهد شد که می‌خواهیم یک تابع محدب را بر مقعر تقسیم کنیم. اگر بنویسیم: $quadoverlin(x + y, \sqrt{y}) \leq x - y + 5$ چون تابع $quadoverlin$ در آرگومان دوم یکنواخت کاهش می‌یابد، بنابراین می‌تواند یک تابع مقعر را در اینجا بپذیرد، و \sqrt{y} مقعر است :۴.۴

مشکل اینجا است که xy مقعر نیست، که باعث می‌شود CVX دستور را رد کند. برای اصلاح این موضوع: $\sqrt{xy - z^2} = \sqrt{y(x - z^2/y)}$ حال می‌توانیم قید ها را به شکل زیر فرمول بندی کنیم: $x + z \leq 1 + geomean([x - quadoverlin(z, y), y])$ زیرا $geomean$ در هر آرگومان مقعر و بدون کاهش است. بنابراین یک تابع مقعر را در آرگومان اول خود می‌پذیرد.